

下面按照你综述中的**六类技术路线**展开。为了便于后续把它整理成论文/课程材料，我把每一类都统一拆成四个问题：

- 1. **基本原理**：motif是在哪里被“表示”出来的？
- 2. **核心算法**：如何从模型内部表示中把 motif 提取出来？
- 3. **Motif 评价**：发现出来以后如何判断它是否可靠、有生物学意义？
- 4. **优缺点**：这种路线真正解决了什么问题，又有什么局限？

需要特别区分一点：**embedding本身并不等于 motif discovery**。真正的技术链条通常是

序列 → 表示学习 → 特征/重要性提取 → motif 实例聚合 → motif 模型构建 → 生物学评价

你综述中的六类方法，主要区别就在于“**从表示中如何提取 motif**”这一环节。综述将其划分为 CNN 卷积核、预训练 LM embedding、SAE、注意力解释、GNN embedding、特征归因/ISM 六类。

一、六类方法的总体框架

先给出一个总览：

类别	Motif 在哪里	核心提取机制	是否需要额外训练	典型 motif 表示
CNN 卷积核	卷积核参数	激活卷积核 → 提取高响应序列	通常需要监督训练	PWM/PSSM
预训练 LM embedding	embedding 空间	embedding/重建/聚类/解释	通常不需要 motif 标注	embedding feature / PWM
SAE	稀疏 latent feature	embedding → SAE → 稀疏特征	需要训练 SAE，但不需要 motif 标签	稀疏 feature + motif
注意力解释	Attention matrix	高注意力区域 → motif	通常无需额外训练	PWM/sequence logo
GNN embedding	graph/node embedding	k-mer 节点注意力/聚合	通常需要任务训练	k-mer motif / graph pattern
特征归因	attribution map	mutation/gradient → 高贡献片段	依赖已有预测模型	importance profile → motif

其中有一个很重要的演化关系：

CNN：motif 是模型参数中的局部滤波器 ↓ Transformer：motif 是模型内部上下文表示中的潜在模式 ↓ Attention：试图从模型的关系矩阵中定位 motif ↓ Attribution：从“模型输出对序列的敏感性”反推 motif ↓ SAE：从 embedding 空间显式分解出稀疏、可解释的 latent feature

这比简单地说“从 CNN 到 Transformer 再到 SAE”更准确，因为它实际上体现了 **motif 表示对象的变化**。

二、CNN 卷积核作为 Motif Detector

代表方法包括 DeepBind、DeepSEA、scBasset。综述中将其定位为最早的一类深度学习 motif discovery 方法，并强调第一层卷积核可以直接充当 motif scanner。

2.1 基本原理

假设 DNA 序列经过 one-hot encoding：

$$X \in \{0, 1\}^{4 \times L}$$

一个长度为 (k) 的卷积核：

$$W \in \mathbb{R}^{4 \times k}$$

在序列上滑动：

$$a_i = f(W \odot X_{i:i+k-1} + b)$$

因此，一个卷积核实际上是在回答：

“这个位置附近是否出现了我学习到的这种序列模式？”

如果某个卷积核在大量具有相同功能的序列上都产生高响应，那么这个卷积核就很可能对应一个 motif。

因此 CNN 的特殊之处在于：

$\text{CNN filter} \approx \text{motif detector}$

2.2 核心算法

典型流程：

```
DNA/RNA sequence
    ↓
One-hot encoding
    ↓
CNN
    ↓
First-layer convolution filters
    ↓
scan sequence
    ↓
high activation sites
    ↓
extract sequence instances
    ↓
align
    ↓
PWM / sequence logo
```

具体来说：

Step 1: 训练 CNN

使用 ChIP-seq、CLIP-seq、ATAC-seq 等监督信号训练模型。

Step 2: 提取第一层卷积核

对于第 (j) 个 filter：

$$W_j = [w_A, w_C, w_G, w_T]$$

可以把其参数直接解释为位置特异性模式。

Step 3: 寻找高激活区域

对于每个序列：

$$i^* = \arg \max_i a_{ij}$$

得到该 filter 最敏感的序列位置。

Step 4: 构造 motif

从大量高激活序列片段中提取 motif instances, 然后:

- clustering
- alignment
- PWM construction

最终形成 sequence logo。

2.3 Motif 评价

这一类方法的评价通常分为三层。

□ 与已知 motif 比较

使用:

- JASPAR
- HOCOMOCO
- CIS-BP
- TRANSFAC

等数据库。

常见方法是 **TOMTOM**。

核心思想是:

$$M_{\text{discovered}} \leftrightarrow M_{\text{known}}$$

比较两个 PWM 的相似性。

□ 分类/预测性能

如果这个 motif 被去掉之后模型性能下降:

$$\Delta Performance = Performance(M) - Performance(M - \text{motif})$$

则说明该 motif 对模型预测具有功能贡献。

□ 生物学验证

例如:

- ChIP-seq binding
 - ATAC-seq accessibility
 - TF binding
 - reporter assay
 - mutagenesis
-

2.4 优点

最大优势是可解释性。

因为 motif 并不是从模型外部“猜”出来的，而是：

卷积核本身就是模型学习到的 pattern detector。

优点包括：

- 结构简单；
 - motif 定位清晰；
 - 易于转换成 PWM；
 - 计算成本低；
 - 结果容易解释。
-

2.5 缺点

□ 一个 filter $\neq$ 一个纯粹 motif

现代 CNN 中，一个卷积核可能学习：

- motif；
- motif + context；
- motif combination；
- 非生物学的统计模式。

因此“一个 kernel 就是一个 motif”其实只是近似。

□ 局部感受野

CNN 天然偏向局部模式：

local pattern

对于：

$motif_A \cdots motif_B$

这种长距离组合关系不够自然。

□ 监督依赖

模型通常是：

$sequence \rightarrow label$

因此发现出来的是与预测任务相关的 motif，而不是所有潜在 motif。

三、预训练 DNA Language Model Embedding

代表包括 DNABERT、Nucleotide Transformer、GPN、HyenaDNA。综述将这一类定义为利用大规模未标注基因组进行 MLM/CLM 预训练，再从 embedding 中提取 motif。

这里需要特别注意：

“预训练 LM”本身不是一种具体的 motif discovery algorithm。

它提供的是一个更强的表示空间:

$$f_{\theta} : \text{sequence} \rightarrow \text{embedding}$$

motif discovery 还需要后面的 extraction mechanism。

3.1 基本原理

以 MLM 为例:

$$x_1, x_2, \dots, x_L$$

随机 mask 一些 token:

$$x_i \rightarrow [MASK]$$

模型学习:

$$P(x_i | x_{\setminus i})$$

经过大规模预训练后, embedding:

$$h_i = f_{\theta}(x_1, \dots, x_L)$$

包含上下文信息。

于是一个核心假设是:

如果某种序列模式具有稳定的生物学意义, 那么预训练模型可能会在 embedding 中编码这种模式。

四、预训练 LM 的 motif discovery 怎么做?

这是这一类最容易混淆的地方。

实际上存在多种 extraction strategy:

路线 A: Attention

$$\text{Embedding} \rightarrow \text{Attention} \rightarrow \text{high-attention region} \rightarrow \text{motif}$$

对应 DNABERT-viz。

路线 B: 输入重建

例如 GPN:

$$\text{embedding} \rightarrow \text{nucleotide reconstruction}$$

通过改变输入碱基观察重建概率变化。

路线 C: embedding clustering

$$h_i \rightarrow \text{clustering} \rightarrow \text{sequence pattern}$$

路线 D: 后续解释模型

例如:

$$LM\ embedding \rightarrow SAE \rightarrow sparse\ feature \rightarrow motif$$

这实际上已经进入下一类 SAE。

因此更严谨地说:

Pretrained LM 是 motif discovery 的 representation backbone, 而不是单独的 motif extraction algorithm.

五、预训练 LM 的 Motif 评价

主要包括:

☐ 已知 motif database matching

例如:

$$\text{discovered motif} \rightarrow \text{JASPAR/CIS-BP/ELM}$$

计算:

- TOMTOM (p)-value
 - similarity
 - database hit rate
-

☐ motif enrichment

比较 motif 在目标序列和背景序列中的富集程度:

$$Enrichment = \frac{P(M|positive)}{P(M|background)}$$

☐ predictive importance

通过:

- masking
- mutation
- perturbation

判断 motif 是否影响模型预测。

☐ biological downstream task

例如:

- TF binding
 - chromatin accessibility
 - enhancer activity
 - splice prediction
 - variant effect prediction
-

优点

相对于 CNN:

□ 不需要大量 motif 标注

可以直接利用:

genome-scale unlabeled sequence

□ 上下文感知

embedding 不只是局部 (k)-mer:

$$h_i = f(x_1, \dots, x_L)$$

因此可能包含:

$$local\ motif + context + long - range\ dependency$$

□ 跨任务迁移

同一个 pretrained model 可以用于:

- motif;
 - variant;
 - regulatory element;
 - gene expression;
 - chromatin accessibility。
-

缺点

最主要的问题是:

embedding 中“有信息”不等于能够直接“读出 motif”。

也就是说:

$$representation \neq interpretation$$

因此出现了后面的:

- attention interpretation;
- attribution;
- SAE。

这三类方法本质上都是在解决:

How do we decode motifs from a pretrained representation?

六、SAE: 从 Embedding 中分解 Motif

这是你综述中最值得重点展开的一类。综述将 MotifAE、InterPLM、SAE-RNA 归入这一范式, 并强调其核心是把 LM embedding 转换成高维、稀疏的 latent features。

6.1 基本原理

假设 PLM 输出:

$$x \in \mathbb{R}^d$$

普通 embedding 的问题是:

一个 embedding dimension 往往混合编码多个生物学概念。

即:

$$x = feature_1 + feature_2 + feature_3 + \dots$$

这就是所谓的 **polysemanticity / feature superposition** 问题。

SAE 希望找到:

$$z \in \mathbb{R}^D, \quad D \gg d$$

且 (z) 是稀疏的:

$$\|z\|_0 \ll D$$

然后:

$$x \approx Dz$$

其中:

- (x): PLM embedding
- (z): sparse latent feature
- (D): decoder dictionary

七、SAE 的核心算法

典型 SAE:

$$z = f(W_e x + b_e)$$

$$\hat{x} = W_d z + b_d$$

优化:

$$\mathcal{L} = \underbrace{\|x - \hat{x}\|^2}_{reconstruction} + \lambda \underbrace{\|z\|_1}_{sparsity}$$

因此:

PLM

↓

embedding

↓

Encoder

↓

high-dimensional sparse latent space

↓

Decoder

↓

reconstruct embedding

真正关键的是：

$$x \rightarrow z$$

如果某一个 latent feature (z_j) 只在一组特定序列模式出现，那么：

$$z_j \approx \text{biological concept}$$

例如可能对应：

- DNA motif;
- protein active-site motif;
- secondary-structure pattern;
- ligand-binding pattern.

八、MotifAE 为什么特别适合 motif discovery?

你综述特别提到了 MotifAE 的 **local similarity loss**。

普通 SAE 主要要求：

$$x \approx \hat{x}$$

但 motif 是一个**局部连续模式**。

因此 MotifAE 进一步要求相邻位置的 latent representation 保持一定一致性：

$$\mathcal{L} = \mathcal{L}_{reconstruction} + \lambda \mathcal{L}_{sparsity} + \alpha \mathcal{L}_{local}$$

于是 latent feature 不仅：

sparse

而且：

spatially coherent

这对于 motif 非常重要。

九、如何从 SAE feature 得到 motif?

假设某个 feature：

$$z_j$$

在大量蛋白序列位置激活。

可以收集：

$$\{s_1, s_2, \dots, s_n\}$$

其中 (s_i) 是 feature 高激活位置附近的序列片段。

然后:

```
SAE feature
  ↓
high activation positions
  ↓
extract sequence windows
  ↓
cluster / align
  ↓
motif
  ↓
PWM / sequence logo
```

于是 SAE 的核心逻辑可以概括为:

$$PLM \rightarrow Embedding \rightarrow Sparse Feature \rightarrow Motif$$

十、SAE Motif 评价

除了传统 database matching, 更重要的是增加:

□ Feature purity

一个 feature 是否主要对应一种生物学模式?

例如:

$$Purity(feature) = \frac{\text{dominant motif instances}}{\text{all activating instances}}$$

□ Activation specificity

feature 是否只在特定 motif 出现时激活?

□ Reconstruction quality

例如:

$$MSE(x, \hat{x})$$

但需要注意:

reconstruction 好并不意味着 motif discovery 好。

因此:

$$Reconstruction\ quality \neq Interpretability$$

□ Known motif recovery

与:

- ELM
- PROSITE
- JASPAR
- Pfam

等数据库比较。

□ Functional alignment

这是 SAE 相比传统 motif discovery 更有潜力的一点。

例如 feature 与:

- protein stability
- binding affinity
- enzymatic activity

之间是否存在对应关系。

□ Feature intervention

进一步直接操控:

$$z_j$$

观察输出:

$$z_j \rightarrow z_j + \Delta$$

是否改变目标功能。

这一步实际上把:

motif discovery

推进到了:

feature discovery → functional interpretation → intervention

综述中提到 MotifAE 已尝试形成这种“发现—验证—操控”闭环。

十一、SAE 的优势与缺点

优势

□ 无监督

不需要:

$$sequence \rightarrow motif\ label$$

□ **feature 数量大**

可以:

$$D \gg d$$

因此理论上可以表示大量细粒度模式。

□ **更接近“概念级”解释**

CNN:

$$filter \rightarrow pattern$$

SAE:

$$latent\ feature \rightarrow biological\ concept$$

□ **有机会发现数据库之外的 motif**

这也是你综述中强调的一个重要趋势。

缺点

□ **SAE 本身也是一个模型**

因此:

$$PLM\ black\ box + SAE\ black\ box$$

并不意味着解释问题完全解决。

□ **Feature 不一定单义**

一个 feature 仍可能包含:

$$motif_A + motif_B$$

即所谓 feature entanglement。

□ **稀疏度存在 trade-off**

太稀疏:

reconstruction 差。

太不稀疏:

interpretability 差。

□ **训练成本高**

尤其是:

$$D = 10^4 \sim 10^6$$

规模的 SAE。

十二、Attention-based Motif Discovery

代表:

- DNABERT-viz
- TF-EPI
- BertSNR

综述将其归为直接利用 Transformer attention matrix 的解释方法。

12.1 基本原理

Transformer 中:

$$Attention(Q, K, V) = softmax\left(\frac{QK^T}{\sqrt{d_k}}\right)V$$

因此得到:

$$A \in \mathbb{R}^{L \times L}$$

其中:

$$A_{ij}$$

表示位置 (i) 对位置 (j) 的注意程度。

核心假设:

如果模型特别关注某些位置, 那么这些位置可能包含功能性 motif。

十三、核心算法: DNABERT-viz

你综述给出的流程非常典型:

```
DNA sequence
↓
DNABERT
↓
Attention matrix
↓
high-attention region
↓
motif instances
↓
statistical enrichment test
↓
alignment
↓
PWM
↓
TOMTOM
```

其中可以进一步拆成:

Step 1

获得:

$$A^{(l,h)}$$

即 layer (l)、head (h) 的 attention。

Step 2

筛选高 attention:

$$A_{ij} > \tau$$

或者寻找连续高分区域。

Step 3

进行统计显著性检验。

Step 4

聚类、对齐。

Step 5

生成 PWM。

十四、Attention 方法的评价

主要看:

☐ Attention 与已知 motif 的 overlap

$$Overlap = \frac{|M_{pred} \cap M_{known}|}{|M_{known}|}$$

☐ motif enrichment

☐ TOMTOM/JASPAR matching

☐ downstream prediction

例如:

masking 掉 attention-selected motif 后, 模型预测性能是否下降?

十五、Attention 方法的关键问题

这是这一类方法必须强调的理论问题:

$Attention \neq Explanation$

即:

attention weight 高, 并不必然意味着该位置对最终 prediction 的因果贡献高。

因此：

- 某个 attention head 可能关注 motif;
- 也可能关注语法关系;
- 也可能只是模型内部的信息路由机制。

综述也明确指出 attention 权重与功能重要性并不完全等价。

十六、GNN / Graph Embedding Motif Discovery

代表方法 MMGAT。综述将其定义为把 k-mer 组成建模成图，通过节点 embedding 和图注意力发现 motif。

16.1 基本原理

与 CNN/Transformer 最大区别是：

不是把序列仅看成一维 token sequence，而是显式构造 graph。

例如：

$$G = (V, E)$$

其中：

- (V): k-mer nodes
- (E): k-mer 之间的关系

例如：

$$kmer_i \rightarrow kmer_j$$

表示它们在序列中具有：

- adjacency;
 - co-occurrence;
 - functional relationship。
-

十七、核心算法：GAT

Graph Attention Network:

$$h'_i = \sigma \left(\sum_{j \in N(i)} \alpha_{ij} W h_j \right)$$

其中：

$$\alpha_{ij} = \text{softmax}_j (a(W h_i, W h_j))$$

于是模型学习：

哪些 k-mer 之间的关系更加重要？

这使它天然适合寻找：

$$motif_A + motif_B$$

这种**组合 motif**。

Motif 提取

可以根据：

- 高 attention edge;
- 高 attention node;
- 高 activation subgraph;

寻找重要的 graph pattern。

最终：

$$important\ subgraph \rightarrow sequence\ pattern \rightarrow motif$$

十八、GNN Motif 评价

除了普通 motif matching，还应该重点评价：

- ☐ node importance
- ☐ edge importance
- ☐ subgraph enrichment
- ☐ motif co-occurrence

尤其是：

$$P(M_B|M_A)$$

以及 motif spacing/orientation。

这是 GNN 方法相比普通 motif discovery 很有价值的地方：

它不仅可能发现“是什么 motif”，还可以研究“motif 与 motif 如何共同出现”。

十九、GNN 的优缺点

优点

- 可以显式建模 motif 共现;
- 能表达组合关系;
- attention 提供一定解释性;
- 适合复杂调控网络。

缺点

- graph construction 本身带有先验;
 - k-mer graph 如何定义会影响结果;
 - 可解释性不如 CNN 直接;
 - 模型复杂度高;
 - 目前应用范围相对有限。
-

二十、特征归因与 In Silico Mutagenesis

这一类包括:

- ISM
- Integrated Gradients
- TF-MoDISco

综述将它们归为从模型输出反向寻找重要序列区域的方法。

它和前面的 Attention 有一个根本区别:

Attention 问的是“模型看哪里?” **Attribution** 问的是“改变哪里会影响模型输出?”

这是非常重要的区别。

二十一、ISM

基本原理

假设序列:

$$x = x_1 x_2 \cdots x_L$$

对第 (i) 个位置进行所有可能突变。

DNA 中:

$$A \rightarrow C, G, T$$

分别计算模型输出:

$$f(x^{i \rightarrow A}), f(x^{i \rightarrow C}), f(x^{i \rightarrow G}), f(x^{i \rightarrow T})$$

与原始预测比较:

$$\Delta_i(b) = f(x^{i \rightarrow b}) - f(x)$$

于是得到:

$$I \in \mathbb{R}^{L \times 4}$$

这就是 nucleotide importance map。

二十二、ISM 如何变成 motif?

ISM 本身实际上不是 motif detector。

它产生的是：

$$sequence \rightarrow importance\ profile$$

然后：

ISM
↓
importance scores
↓
high-importance regions
↓
extract sequence segments
↓
cluster
↓
align
↓
motif

因此：

$$ISM = attribution$$

而不是：

$$ISM = motif\ discovery$$

这一区分对于你的综述非常值得强调。

二十三、ISM 的评价

□ 与已知 motif overlap

□ deletion/mutation validation

把 motif 删除：

$$f(x) - f(x_{\setminus motif})$$

看模型输出是否显著下降。

□ insertion test

把 motif 插入背景序列：

$$f(background + motif)$$

是否产生预期功能？

这比单纯数据库匹配更接近功能验证。

二十四、Integrated Gradients

ISM 的问题是：

$$3L$$

次前向传播。

因此对于长序列非常昂贵。

Integrated Gradients 从 baseline:

$$x'$$

到真实输入：

$$x$$

沿路径积分：

$$IG_i(x) = (x_i - x'_i) \int_0^1 \frac{\partial F(x' + \alpha(x - x'))}{\partial x_i} d\alpha$$

从而获得每个位置的 attribution。

因此：

ISM : perturb explicitly

而：

IG : integrate gradients

二十五、TF-MoDISco

TF-MoDISco 是这一类中特别重要的“从 attribution 到 motif”算法。

它不是直接生成 attribution，而是：

把已有 attribution map 转化成 motif。

基本流程：

Deep model

↓

gradient / DeepSHAP / IG

↓

importance scores

↓

select high-scoring sequence segments

↓

sequence + attribution clustering

↓

motif instances

↓

alignment

↓

motif

也就是说：

$$Attribution \rightarrow TF - MoDISco \rightarrow Motif$$

二十六、TF-MoDISco 的核心思想

不能只按照 sequence similarity 聚类。

因为：

ACTGTT

和

ACCGTT

可能是相似 motif;

但是：

AAAAAA

如果模型认为没有功能贡献，就不应该因为 sequence similarity 被识别成 motif。

因此 TF-MoDISco 同时利用：

$$sequence\ similarity + importance\ similarity$$

来聚类。

这一点是它比单纯 sequence clustering 更适合深度模型 motif discovery 的原因。

二十七、六类方法的核心差异

如果把六类方法放在一起，可以得到一个非常清晰的框架：

方法	它观察什么？	Motif 如何产生？	最核心的问题
CNN	filter activation	filter $\rightarrow$ motif	模型学到了什么局部模式？
PLM embedding	hidden representation	representation $\rightarrow$ pattern	embedding 中编码了什么？
SAE	sparse latent feature	latent feature $\rightarrow$ motif	能否把混合表示拆开？
Attention	attention matrix	high attention $\rightarrow$ motif	模型“关注”哪里？
GNN	node/edge/subgraph	important graph pattern $\rightarrow$ motif	哪些模式共同出现？
Attribution	output sensitivity	high attribution $\rightarrow$ motif	哪些位置真正影响预测？

这张表实际上比“六类模型”更能体现这篇综述的技术逻辑。

二十八、Motif 评价最好建立一个统一体系

你原综述目前对“motif 评价”的讨论相对弱。第 5.1 节只指出目前评价过度依赖 JASPAR、ELM、CIS-BP 等已知数据库。

如果要把综述进一步提升，我建议把评价明确拆成 **四个层次**：

Level 1: Pattern-level

评价“长得像不像 motif”。

包括：

- PWM similarity
- sequence logo
- TOMTOM
- edit distance
- information content

核心问题：

Is it a recognizable sequence pattern?

Level 2: Enrichment-level

评价 motif 是否在目标数据中显著富集。

例如：

$$OR = \frac{a/b}{c/d}$$

以及：

- Fisher's exact test
- hypergeometric test
- FDR

核心问题：

Does this pattern occur more frequently than expected?

Level 3: Predictive-level

评价 motif 对模型预测是否重要：

$$\Delta F = F(X) - F(X_{\setminus M})$$

或者：

$$F(X + M) - F(X)$$

核心问题：

Does the motif matter for the learned function?

Level 4: Biological / Causal-level

最高层次是：

$$motif \rightarrow molecular\ function$$

例如：


- ChIP-seq validation;

- reporter assay;
- CRISPR perturbation;
- protein mutagenesis;
- binding affinity;
- enzymatic activity;
- stability assay。

核心问题：

Does manipulating the motif change the biological phenotype?

二十九、因此可以建立一个更完整的评价金字塔



这实际上对应了 motif discovery 从：

“发现一个看起来像 motif 的东西”

逐步走向：

“证明它是一个具有功能作用的 motif”。

三十、六类方法的优缺点最终对照

方法	主要优势	主要缺点	最适合解决的问题
CNN	简单、快速、直接可解释	局部性强、依赖监督	已知任务中的局部 motif
PLM	表示能力强、上下文丰富、可迁移	embedding 本身难解释	从大规模无标注数据学习序列规律
SAE	无监督、特征稀疏、可发现细粒度模式	SAE 训练复杂、feature 仍可能纠缠	从 PLM 中发现潜在生物学概念
Attention	无需额外模型、直接利用 Transformer	attention $\neq$ causal importance	快速定位候选 motif
GNN	能建模 motif 共现和组合关系	graph construction 较强依赖先验	组合 motif / motif grammar
ISM/IG/TF-MoDISco	与模型输出直接关联、可做扰动验证	计算成本/依赖已有预测模型	找到真正影响模型预测的序列区域

三十一、我认为这篇综述最值得修改的一点

目前你的六分类存在一定的分类层级混杂。

例如：

CNN、GNN 是模型架构；DNABERT、NT、GPN 是表示学习模型；SAE 是解释模型；Attention 是解释信号；ISM、IG 是归因方法。

它们其实不是同一个层级。

因此，如果这是准备正式发表的综述，我更建议把整个领域重新组织成下面这个框架：

第一层：Representation Backbone

<i>CNN</i>		<i>Transformer/PLM</i>		<i>GNN</i>
------------	--	------------------------	--	------------

第二层：Motif Extraction / Interpretation

<i>Filter activation</i>		<i>Attention</i>		<i>Attribution</i>		<i>SAE</i>		<i>Clustering</i>
--------------------------	--	------------------	--	--------------------	--	------------	--	-------------------

第三层：Motif Reconstruction

<i>instances</i>	→	<i>clustering</i>	→	<i>alignment</i>	→	<i>PWM</i>
------------------	---	-------------------	---	------------------	---	------------

第四层：Motif Validation

<i>database</i>	→	<i>enrichment</i>	→	<i>prediction</i>	→	<i>functional/causal</i>
-----------------	---	-------------------	---	-------------------	---	--------------------------

这样整个领域就从“六种互相并列的方法”变成了一个统一的：

Representation → Extraction → Reconstruction → Validation

pipeline。

这可能比目前综述中“六大类并列”的分类更有理论解释力，也更容易自然地引出你在第 4 节所说的从 CNN 到 PLM、从监督到无监督、从描述到功能的演化趋势。综述目前已经明确观察到了这些趋势，只是分类框架还没有完全把这种演化关系表达出来。